流量治理：多层闸门的业务视角

TokenBucket / SlidingWindow / CircuitBreaker / 异步削峰 / HTTP cache

gomall · 业务侧 deck (v2)

今日大纲

第一层：TokenBucket 全局兜底

第二层：SlidingWindow 用户精确限流

第三层：CircuitBreaker 保护慢依赖

第四层：异步下单削峰

第五层：HTTP cache 把读路径 CDN 化

流量治理是一个” 分层叠加” 的工程

- 单一阈值挡不住所有场景：
  - DDoS 几十万 QPS，网关层就要拦；
  - 黑产用户 5 QPS 持续刷一天，要在用户维度拦；
  - 第三方支付 30s 超时，要在依赖维度拦。
- gomall 把治理拆成 5 层叠加：**TokenBucket / SlidingWindow / CircuitBreaker / 异步削峰 / HTTP cache**。
- 每一层解决一个具体的业务问题，组合起来才能扛住大促。

routes/router.go:22 全局 / *:40 HTTP cache* / *:94* 异步入队 / *:114* 熔断 / *:136* 滑动窗口

gomall 五层闸门的业务定位

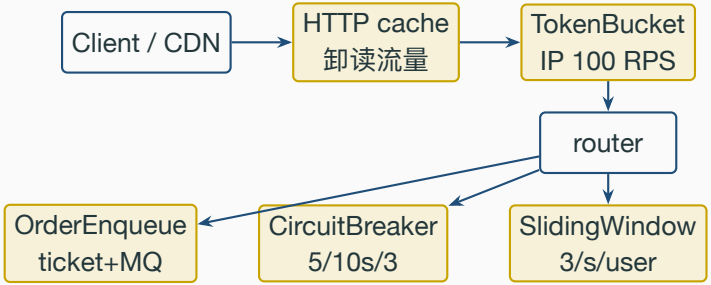

五层并不是” 流水线串联”，而是按接口按业务分级**挑选挂载**。*routes/router.go* 全文 *mount* 点

核心 P0 vs 营销 P2：阈值取舍完全不同

等级	接口举例	限流姿态	熔断
P0 交易	/orders/create, /paydown	不挂用户限流	必须有
P1 读	/product/show, /carousels	HTTP cache	不需要
P2 秒杀	/skill_product/skill	用户 3/s 激进	不需要
P2 红包	/redpacket/claim	用户 3/s	不需要
P3 信息	/category/list, 轮播图	全局 + CDN	不需要

P0 宁可下游慢、不能

上游 429；P2 宁可误杀、不能让黑产薅光。

两类接口同一套阈值是行不通的。*routes/router.go:22, 39–45, 76–84, 92, 114–119, 136–142*

第一层：TokenBucket 全局兜底

为什么全局还要 100 RPS / 200 burst

- gomall 单机基线 **64,254 RPS**（`/ping`），单 IP 真正用户用不到 1/600。
- 100 RPS / 200 burst 实际拦的是**爬虫脚本和异常客户端**，不是用户。
- burst 给到 2× rps 的依据：
  - 浏览器一个页面 30+ 静态 GET 是常态，瞬时 burst ≈ 100；
  - burst 留 200 = 让一次正常加载**绝不触发**。
- 这层是**兜底**：业务层的精细限流挂掉时，至少不会被压死。

routes/router.go:22 TokenBucket(rate.Limit(100), 200)

TokenBucket 算法：桶 + 令牌生成 + 漏出

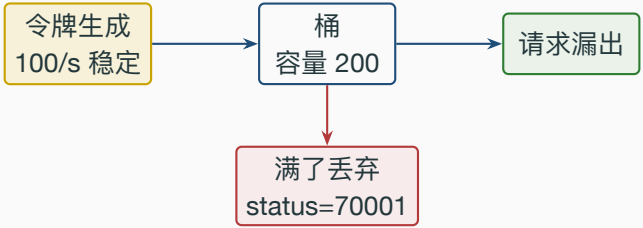

- 令牌按 **rps** 匀速生成；桶满则溢出。
- 请求拿到令牌才放行，拿不到立刻返回 70001。
- burst 容量决定能否吸收**瞬时尖刺**（比如页面首屏并发）。

middleware/ratelimit.go:22–49 golang.org/x/time/rate 实现

TokenBucket 中间件实现 (逐行)

Listing 1: *middleware/ratelimit.go:22–49*

```go
22 func TokenBucket(rps rate.Limit, burst int) gin.HandlerFunc {
23    var mu sync.Mutex
24    limiters := make(map[string]*rate.Limiter)
25    get := func(ip string) *rate.Limiter {
26       mu.Lock(); defer mu.Unlock()
27       if l, ok := limiters[ip]; ok { return l }
28       l := rate.NewLimiter(rps, burst); limiters[ip] = l; return l
29    }
30    return func(c *gin.Context) {
31       if !get(c.ClientIP()).Allow() {
32          c.JSON(200, gin.H{"status": e.ErrRateLimitExceeded})
33          c.Abort(); return
34       }
35       c.Next()
36    }
37 }
```

map 按 IP 隔离；每 IP 一个 `rate.Limiter`；`Allow()` 非阻塞；拒了直接 70001；进程内 map 是单机代价，多实例要 Redis token bucket。

第二层：SlidingWindow 用户精确限流

秒杀为什么必须用 SlidingWindow

- 秒杀的**业务对手**是脚本，不是用户：
  - 真人最快点击 **300–500ms 一次** → 1s 最多 2–3 次；
  - 脚本可以 1s 打 1000 次。
- 阈值定 **3/s/用户**：
  - 真用户：留 50% 余量给” 双击 + 网络重试”；
  - 黑产：第 4 次开始 70001 截断。
- TokenBucket 不够：
  - 必须按**用户 ID**（不是 IP）限，否则一个 NAT 出口下所有用户共享一个桶；
  - 必须**分布式精确**，多实例下用 Redis 共享状态。

routes/router.go:136–142 SlidingWindow Scope:seckill Limit:3 Window:1s ByUser:true

SlidingWindow 在 Redis ZSet 上的实现

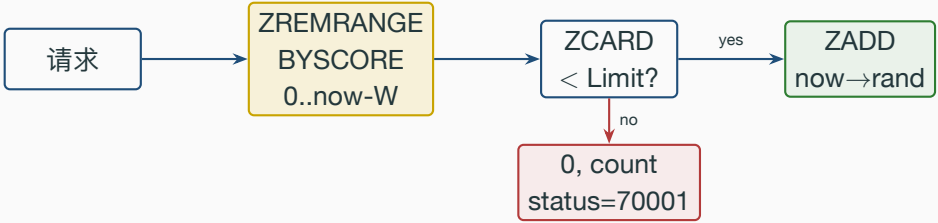

- 每个用户一个 ZSet：`rl:seckill:user:42`；
- score = 请求时间戳（ms）；member = ” 时间戳 + 6 字节随机” 避免同毫秒冲突；
- 滑动窗口 = 每次请求先**踢掉 window 之外的旧记录**，再 ZCARD 数当前窗口内的请求数。

repository/cache/ratelimit.go:18–34 Lua 脚本; middleware/ratelimit.go:69–104 调用方

SlidingWindow Lua 脚本 (逐行)

Listing 2: *repository/cache/ratelimit.go:18–34*

```lua
local key, window_ms = KEYS[1], tonumber(ARGV[1])
local limit, now_ms, member = tonumber(ARGV[2]), tonumber(ARGV[3]), ARGV[4]
redis.call('ZREMRANGEBYSCORE', key, 0, now_ms - window_ms)
local count = redis.call('ZCARD', key)
if count >= limit then return {0, count} end
redis.call('ZADD', key, now_ms, member)
redis.call('PEXPIRE', key, window_ms)
return {1, count + 1}
```

逐行：① 入参 key/窗口/阈值/now/请求 id；② **ZREMRANGEBYSCORE** 滑掉过期（关键）；③ ZCARD 数当前窗口；④ 超阈值返回 0；⑤ 通过则 ZADD 入；⑥ PEXPIRE 自动回收；⑦ **整脚本单原子**，无竞态。

压测实测：3/s/user 阈值校验

场景：30 VU × 15s 打 `/skill_product/skill`，共用同一 token。

指标	实测	业务期望
通过请求数	**46**	15s × 3 = 45
被限流数	781,624	黑产全拦
单接口 RPS	52,082	与 ping 同量级
误差	2.2%	< 5%

通过 46≈" 真用户 15s 最多秒杀 45 次"；被限 78 万次说明脚本成本被推到客户端，服务端只做一次 Lua RTT。*stressTest/REPORT.md §5；stressTest/seckill_rate_limit.js*

红包接口：同一套机制再用一次

- `/redpacket/claim` 也是 **Limit:3 Window:1s ByUser:true**（router.go:79–84）。
- 与秒杀不同的是：红包额外挂**幂等**（避免一次抢包重复扣余额）。
- 这印证了一个体例：**SlidingWindow 是 P2 营销接口的” 标配”**，按用户维度反黑产；幂等是 P0/P2 资金链路的” 标配”。
- gomall 把这两个中间件设计成可以**任意组合**，business team 只用写一行声明。

routes/router.go:79–84 红包抢包；*:136–142* 秒杀；*:92, 94, 114, 120* 幂等链

第三层：CircuitBreaker 保护慢依赖

熔断保护的不是自己，是下游

- gomall `/paydown` 的下游 = 第三方支付（Stripe / 微信 / 支付宝）。
- 这种依赖的**失败模式**是慢，不是 500：
  - 正常 RT 200ms；
  - 异常时 RT 30s 才超时；
  - 不熔断 → goroutine 堆积 → 内存爆 → 自己跟着挂。
- CircuitBreaker 的业务含义：**”我代下游回答你不行，免得你等 30 秒”**。
- 三态阈值 **5 失败 / 10s 等待 / 3 探测**（router.go:114–119）：
  - 5 = 容忍偶发抖动，不会一抖就跳；
  - 10s = 给下游一个完整告警 + 自愈周期；
  - 3 = 探测窗口够小，避免 HalfOpen 也被打爆。

routes/router.go:114–119 三态阈值

CircuitBreaker 三态机

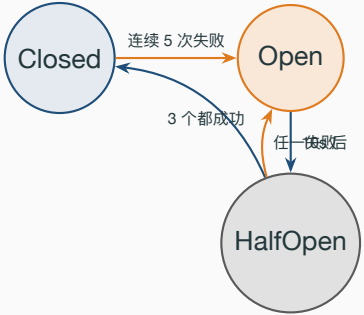

Closed：放行所有，连续 5 次失败 → Open。**Open**：直接返回 70002，10s 后试探。**HalfOpen**：放 3 个探测，全成功 → Closed；任一失败 → Open。*middleware/circuitbreaker.go:76–128 allow + report*

CircuitBreaker.allow 状态转移 (逐行)

Listing 3: *middleware/circuitbreaker.go:76–106 allow*

```go
76  func (cb *circuitBreaker) allow() error {
77     switch circuitState(cb.state.Load()) {
78     case stateClosed: return nil // 1) 关闭态零开销
79     case stateOpen:
80        if time.Now().UnixNano()-cb.openedAt.Load() < int64(cb.opt.OpenTimeout) {
81           return errCircuitOpen // 2) Open 期间一律拒
82        }
83        cb.mu.Lock(); defer cb.mu.Unlock()
84        if circuitState(cb.state.Load()) == stateOpen { // 3) 锁内 double-check
85           cb.state.Store(int32(stateHalfOpen))
86           cb.halfOpenReq.Store(0)
87        }
88        fallthrough // 4) 进入 HalfOpen
89     case stateHalfOpen:
90        if cb.halfOpenReq.Add(1) > cb.opt.HalfOpenMaxReq {
91           return errCircuitOpen // 5) 探测超限退回
92        }
93        return nil
94     }
95     return nil
96  }
```

 Closed 仅 atomic load； Open 内不查时间就拒； Open→HalfOpen 锁内 double-check； HalfOpen 用

report：决定下一刻是 Closed 还是 Open

Listing 4: *middleware/circuitbreaker.go:108–128 report*

```go
func (cb *circuitBreaker) report(failed bool) {
   switch circuitState(cb.state.Load()) {
   case stateClosed:
      if failed {
         if cb.failures.Add(1) >= cb.opt.FailureThreshold {
            cb.tripOpen() // 连续失败到阈值
         }
      } else { cb.failures.Store(0) } // 成功重置
   case stateHalfOpen:
      if failed { cb.tripOpen() // 任一失败 -> Open
      } else if cb.halfOpenReq.Load() >= cb.opt.HalfOpenMaxReq {
         cb.state.Store(int32(stateClosed)) // 全成功 -> Closed
         cb.failures.Store(0)
      }
   }
}
```

 Closed 失败计数； 成功重置避免偶发抖动跳闸； HalfOpen **非对称**——任一失败立即回 Open，必须全成功才回 Closed； ”信任成本”对资金链路合适：宁保守不再打死下游。

熔断 + 幂等的三角配对：Open 返回 200 + 70002

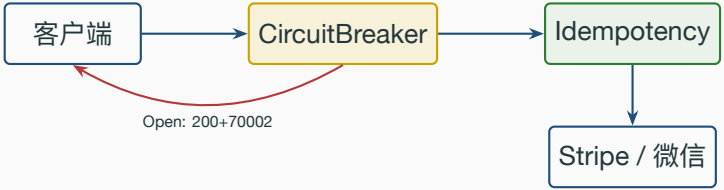

- Open 返回 **200 + status=70002**（不是 5xx）：app 端老网关吞不了 5xx，统一业务码客户端只用一套 switch。
- 客户端拿 70002 指数退避（1s/2s/4s）；重试必须带原 Idempotency-Key。
- paydown 同时挂 CB + Idempotency 不是巧合：缺一边都不行。

routes/router.go:114–121；middleware/circuitbreaker.go:57–65；pkg/e/code.go:58

第四层：异步下单削峰

双 11 0 点：100k QPS 怎么扛

- 同步下单链路：HTTP → ReserveStock → INSERT order → COMMIT → 回客户端，p99 大约 50–100ms。
- 100k QPS × 100ms = **1 万并发**进 MySQL，连接池打爆。
- gomall 的方案：把”DB 落库” 从同步链路里拆出来。
  1. 同步部分：reserve 库存 + 写 ticket + 投 MQ → 返回 ticket；
  2. 异步部分：consumer 慢慢消费 MQ → INSERT order → 回写 ticket 状态；
  3. 客户端：拿 ticket 轮询 `/orders/status`。
- 收益：DB 压力从” 瞬时尖刺” 变成” 恒定 1k QPS 平流”。

service/order_async.go:119–172 OrderEnqueue

同步下单 vs 异步 ticket 链路

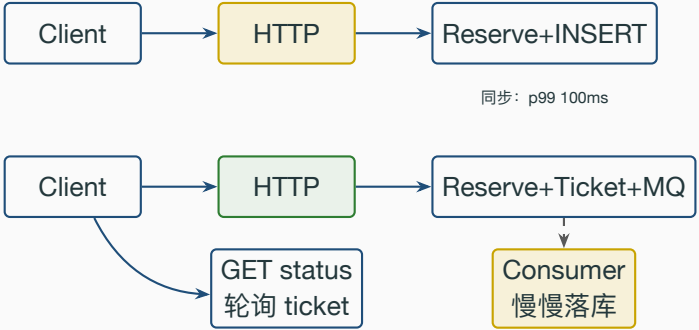

上：所有客户端被 DB 阻塞；

下：客户端 5ms 拿到 ticket，DB 压力被 MQ 缓冲。*api 层：EnqueueOrderHandler + OrderStatusHandler; service/order_async.go*

OrderEnqueue：核心 12 行

Listing 5: *service/order_async.go:119–172*

```go
func (s *OrderSrv) OrderEnqueue(ctx, req) (interface{}, error) {
   u, _ := ctl.GetUserInfo(ctx)
   if err := cache.ReserveStock(ctx, req.ProductID, req.Num); err != nil {
      return nil, err // 1) 库存预扣
   }
   ticket := fmt.Sprintf("%d", snowflake.GenSnowflakeID()) // 2) ticket
   if err := defaultTicketStore.Put(ctx, ticket,
      OrderTicketStatus{Status: "pending"}, time.Hour); err != nil {
      _ = cache.ReleaseReservation(...); return nil, err // 3) 写 Redis
   }
   body, _ := json.Marshal(AsyncOrderTask{Ticket: ticket, ...})
   if err := defaultAsyncProducer.Publish(ctx, body); err != nil {
      _ = cache.ReleaseReservation(...); return nil, err // 4) 投 MQ
   }
   return OrderEnqueueResp{Ticket: ticket, Status: "pending"}, nil
}
```

 库存预扣前置，不足直接拒； snowflake 生成 ticket 无 DB； Redis pending 给前端轮询； 任一步失败 **ReleaseReservation** 回滚库存； 投递成功才算入队。

第五层：HTTP cache 把读路径 CDN 化

读流量的最优解：根本不到 gomall

- P1 P3 读接口（`/product/show`, `/carousels`, `/category/list`）的数据更新频率**远低于查询频率**。
- 让浏览器 / CDN 缓存代答：
  - 浏览器：直接返回 304 Not Modified（不传 body）；
  - CDN：命中缓存（不到 gomall）。
- gomall 实现：`HTTPCache(maxAge)` 中间件统一发 ETag + Cache-Control。

middleware/httpcache.go:47–100 HTTPCache; routes/router.go:39–45 挂载点

HTTP cache 的三种命中

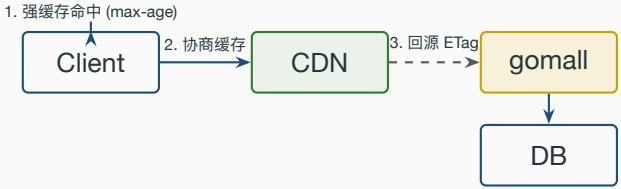

- **强缓存**（Cache-Control: max-age=60）：浏览器本地命中，0 RTT；
- **协商缓存**（ETag + If-None-Match）：到 CDN，命中返回 304，无 body；
- **回源**：CDN 不命中，回 gomall；ETag 用 SHA-256 前 16 字节算。

middleware/httpcache.go:78–98 ETag 协商；routes/router.go:39 product/list max-age=30

各接口的 max-age 定多少

接口	max-age	业务依据
/product/list	30s	价格 / 库存可能变化，不能太长
/product/show	60s	商品详情更稳定
/category/list	300s	分类几乎不变
/carousels	300s	运营手动调，时效性弱

max-age 的**业务取舍**：

太长会让” 改价 / 下架” 延迟生效，太短卸不了流量。

300s = 运营改完最多 5min 生效，可接受；30s = 库存接近灵敏阈值的折中。

routes/router.go:39–45 各路由的 *maxAge* 参数

多层流控漏斗：DDoS → IP → 用户 → 业务

L1 网络：CDN / Anti-DDoS（云厂商）

↓

L2 网关：IP TokenBucket（gomall）

↓

L3 业务：用户 SlidingWindow（gomall）

↓

L4 风控：设备指纹 / 行为模型（外部）

- gomall 自己负责 L2 + L3，挡住**绝大部分业务异常流量**。
- L1 / L4 通常由云厂商和独立风控团队提供，不自己造。

routes/router.go:22 (L2); :136–142 (L3)

业务码 70001 / 70002：客服话术对照

业务码	业务含义	客服话术
70001	限流命中	”活动太火爆，请稍后重试”
70002	熔断开启	”支付暂忙，1 分钟后再试”
60002	幂等命中	”您已下单成功，无需重复”
50001	库存不足	”已售罄”

同样是”请稍后”，70001 客户端重试就能过、70002 必须等下游自愈、60002 是用户自己重复了。

区分话术比统一一句”系统繁忙”对用户更友好，对客服也更省事。*pkg/e/code.go:57–58* 业务码；*pkg/e/msg.go:51–52* 消息

error budget：用数字管” 什么时候停发版”

- P0 SLO=99.95% → 月度**宕机预算 ≈ 21min**。
- 烧 1/3（7min）减发版；烧 2/3（14min）冻结非紧急；全烧光 → 下月转” 稳定性 only”。
- 预算用 SLI 推：限流命中率 / 熔断打开时间 / 5xx 比例累加成” 不可用时间”。

> 流量治理不是**一个机制**，是**五个机制按业务等级组合**。
> 每个阈值都要能用业务语言解释清楚。

Google SRE error budget 原则；*stressTest/REPORT.md* 链路稳定性数据

面试 Q&A (1/2)

Q1：100 RPS / 200 burst 这两个数字怎么定?

A：基线 64k RPS / 单 IP 用不到 1/600，100 留给爬虫脚本做兜底；burst 200 容纳一次首屏并发 100+，不会误伤真用户。

Q2：为什么秒杀用 SlidingWindow 不用 TokenBucket?

A：① 必须按用户而不是 IP，否则 NAT 出口全员共享；② 必须分布式精确，多实例下用 Redis 共享状态；③ ZSet 比 fixed-window 没有窗口边界可以利用。

Q3：CircuitBreaker 5/10s/3 三个数字有什么讲究?

A：5 = 容忍偶发抖动不一抖就跳；10s = 给下游一次完整告警 + 自愈周期；3 = HalfOpen 探测够小，避免再次打死下游。

面试 Q&A (2/2)

Q4：异步下单是不是会丢单?

A：不会。库存先 Reserve（Redis Lua 原子），任一失败都 ReleaseReservation 回滚；ticket TTL=1h 兜底；MQ 用 RabbitMQ 持久化 + 手动 ack。

Q5：为什么熔断返回 200 不返回 503?

A：app 端老网关不能优雅处理 5xx；统一走业务码（70002）= 客户端只用维护一套 status switch；监控不要按 4xx/5xx 算错误率，必须看 status。

Q6：HTTP cache 的 max-age 怎么定?

A：取决于” 改价 / 下架” 的最大可接受延迟。商品详情 60s，分类 / 轮播 300s，列表 30s（库存敏感）。

代码位置一览

router 挂载点	*routes/router.go:22, 39–45, 79–84, 94, 114–121, 136–142*
TokenBucket	*middleware/ratelimit.go:22–49*
SlidingWindow	*middleware/ratelimit.go:59–106 + repository/cache/ratelimit.go:18–34*
CircuitBreaker	*middleware/circuitbreaker.go:44–136*
HTTPCache	*middleware/httpcache.go:47–100*
OrderEnqueue	*service/order_async.go:119–172*
业务码	*pkg/e/code.go:57–58 / msg.go:51–52*
压测报告	*stressTest/REPORT.md §1, §5*

配套技术 deck：05-ratelimit-circuit-breaker.tex（机制视角）